Работа с количественными данными

Константин Житков
Аналитик в лаборатории
«Развитие университетов»
НИУ ВШЭ

Зачем вообще нужны количественные данные?

Готовые данные

- Мониторинг эффективности вузов
- Мониторинг трудоустройства выпускников
- **Траектории в образовании и профессии**
- Формы ВПО-1 с данными по регионам
- РМЭЗ

Теория

Что можно делать с цифрами?

1. Предсказывать события
2. Искать причинно-следственные взаимосвязи
   A. Экстраполировать результаты исследований

Моделирование

Балл ЕГЭ зависит от

школы, в которой учился абитуриент,

региона, в котором он проживает,

занятий с репетитором

И для предсказания и для причинно-следственной взаимосвязи модель строится одинаково

Моделирование

Балл ЕГЭ = 50 + 0,2*лицей + 1,5*Москва + 3*Занятия с репетитором - 0,75*Число пойманных покемонов

Модель 1

Балл ЕГЭ = 52 + 0,1*лицей + 1,55*Москва + 2,5*Занятия с репетитором - 0,7*Число пойманных покемонов - 0,2*возраст ученика

Модель 2

Статистическая взаимосвязь ≠ причинно-следственной

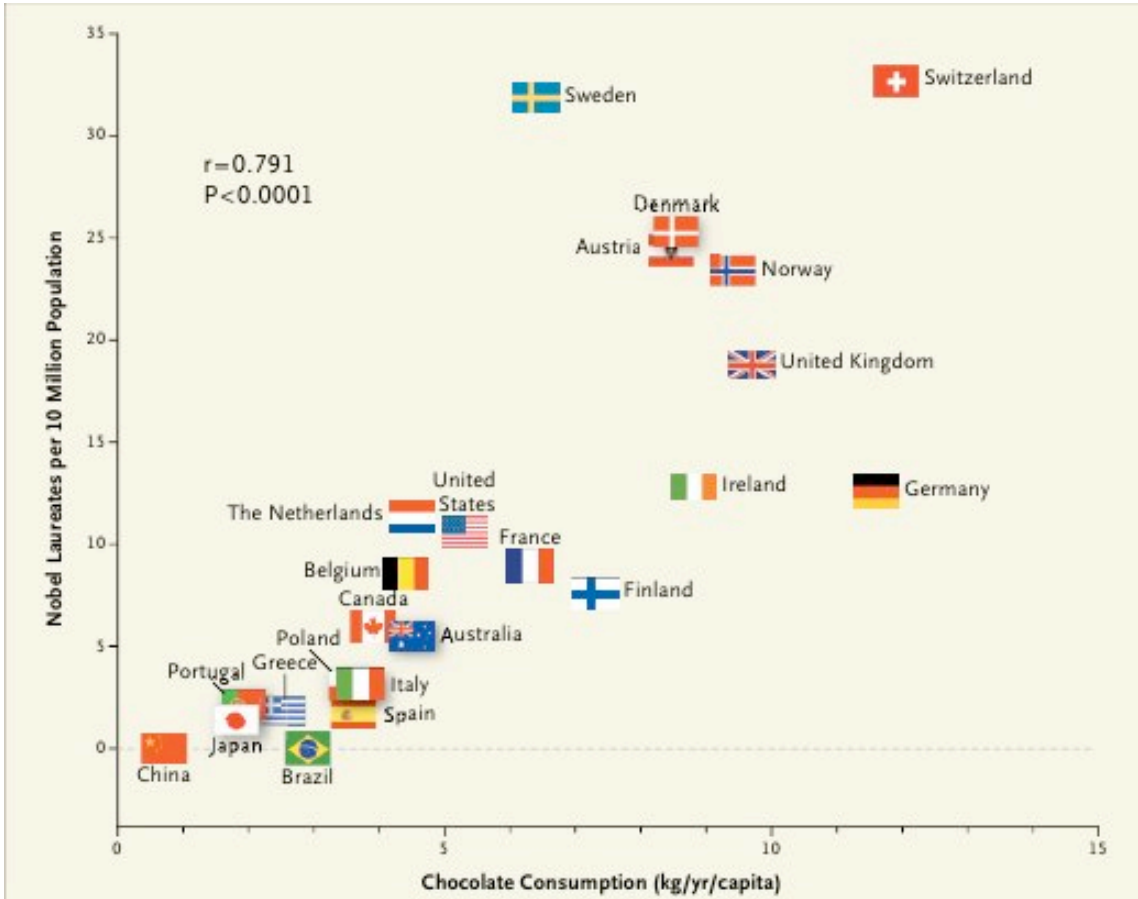

Figure 1. Correlation between Countries' Annual Per Capita Chocolate Consumption and the Number of Nobel Laureates per 10 Million Population.

Причинно-следственная связь

- Идеальные данные для этого – экспериментальные
- Можем ли мы их получить?

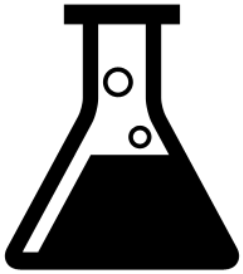

Как проверить своё исследование?

- Смотрим как люди раньше делали подобные исследования
- Пробуем несколько возможных моделей
- Думаем, не упустили ли мы чего-то важного. Если да, то движемся в направлении более продвинутых методов (matching)

Краткое содержание первой части

1. С помощью данных моделируем взаимосвязь показателей
2. Либо пытаемся предсказать будущее
3. Либо ищем причинно-следственную взаимосвязь
4. Спрашиваем себя: для какой группы людей верны полученные результаты?

Практика

Данные ТРОП

- С 2011 года школьникам каждый год задают вопросы о учебе, стремлениях, социально-экономическом статусе
- Выборка репрезентирует население России

Этапы работы с данными

- Чаще всего до постановки конкретного вопроса вы тратите много времени на подготовку данных
- Вы должны знать, как выглядят ваши данные

Проверка данных

- Пролистайте всю таблицу
- Посмотрите первые и последние 10 строк
- Лишние знаки препинания, заглавные буквы, пробелы
- Пример из практики: некоторые люди указали в анкете ТРОП несуществующие вузы

Проверки данных не бывает мало

- Отрицательный возраст
- Балл ЕГЭ больше 100 и меньше 0
- Число зачисленных больше числа поданных заявлений
- Есть колонка с суммой и колонки, из которых эта сумма была получена. Перепроверьте этот результат

Проверки данных не бывает мало никогда

- Кого ваша выборка хорошо описывает?
- Когда будете делать выводы – делайте поправку на это условие, чтобы не породить искусственных сенсаций

Описательные статистики

- Считаем:
  - среднее
  - медиана
  - мода
  - стандартное отклонение
  - минимум
  - максимум

А в чем смысл первых четырёх?

Номер вуза	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**
Число общежитий	1	1	2	3	4	2	1	4

Среднее = Сумма всего/количество =
= (1 + 1 + 2 + 3 + 4 + 2 + 1 + 4)/8 = 2,25

Медиана = То, что посередине =
= Упорядочиваем от мин. к макс. =
= 1 1 1 2 2 3 4 4 =
= среднее из 2 2 = 2

Мода = Самое частое значение =
= 1 (встречается 3 раза)

Ст. отклонение = насколько данные разбросаны вокруг среднего

Картинки

- Базовый набор картинок:
  - Столбиковая диаграмма (bar plot)
  - Гистограмма
  - Графики плотности

Грамотный график не требует текстового разъяснения

Хороший тон в картинках

- Никаких объемов
- Оси и их единицы измерения подписаны
- Есть заголовок
- График пронумерован
- График должен помогать читателю, а не путать его

Как не надо делать

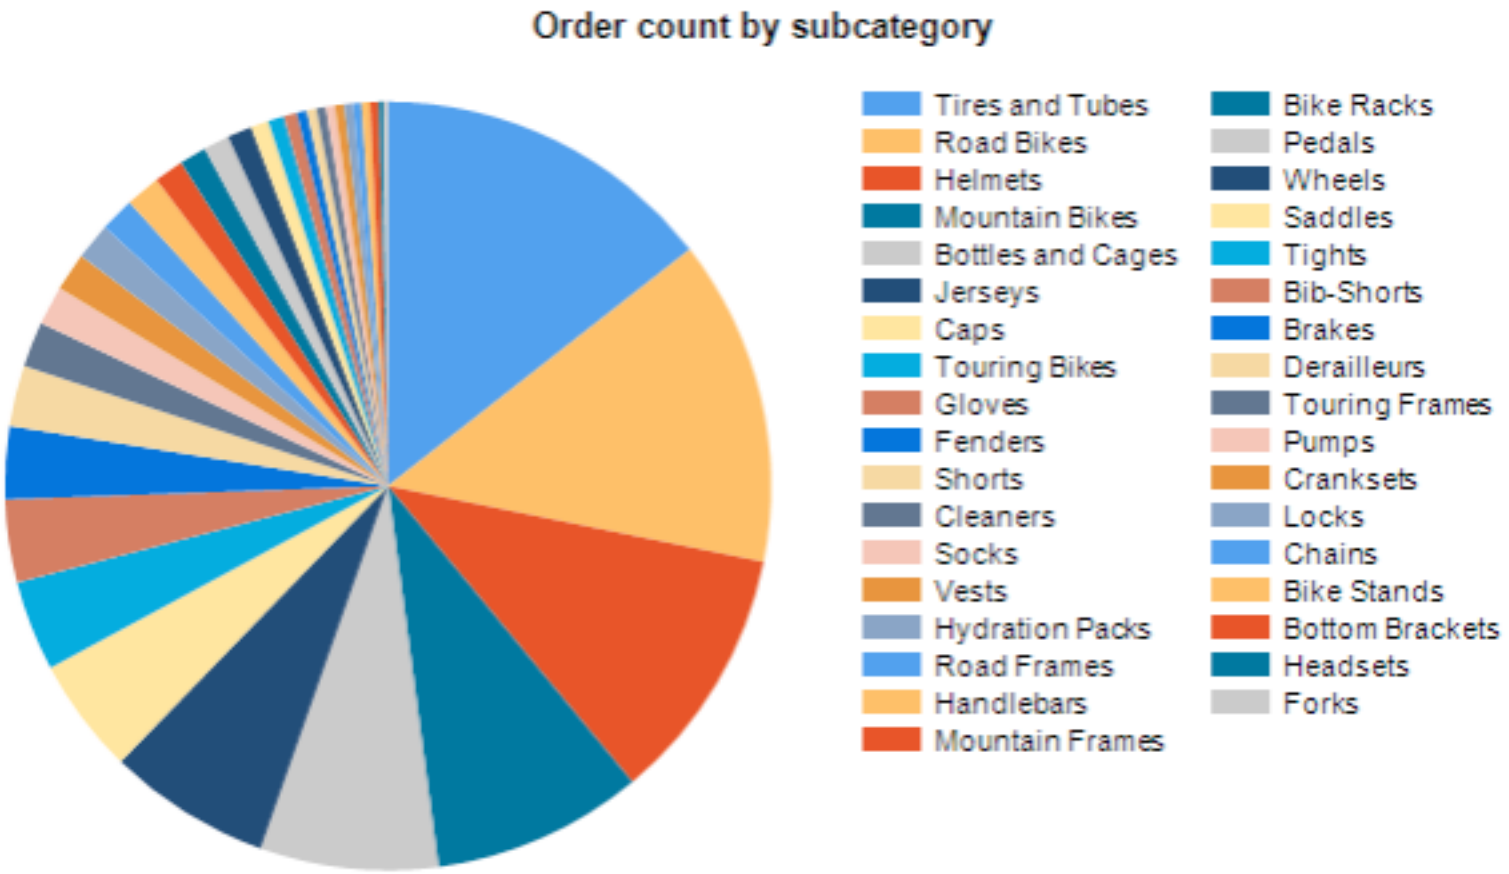

Как совсем не надо делать

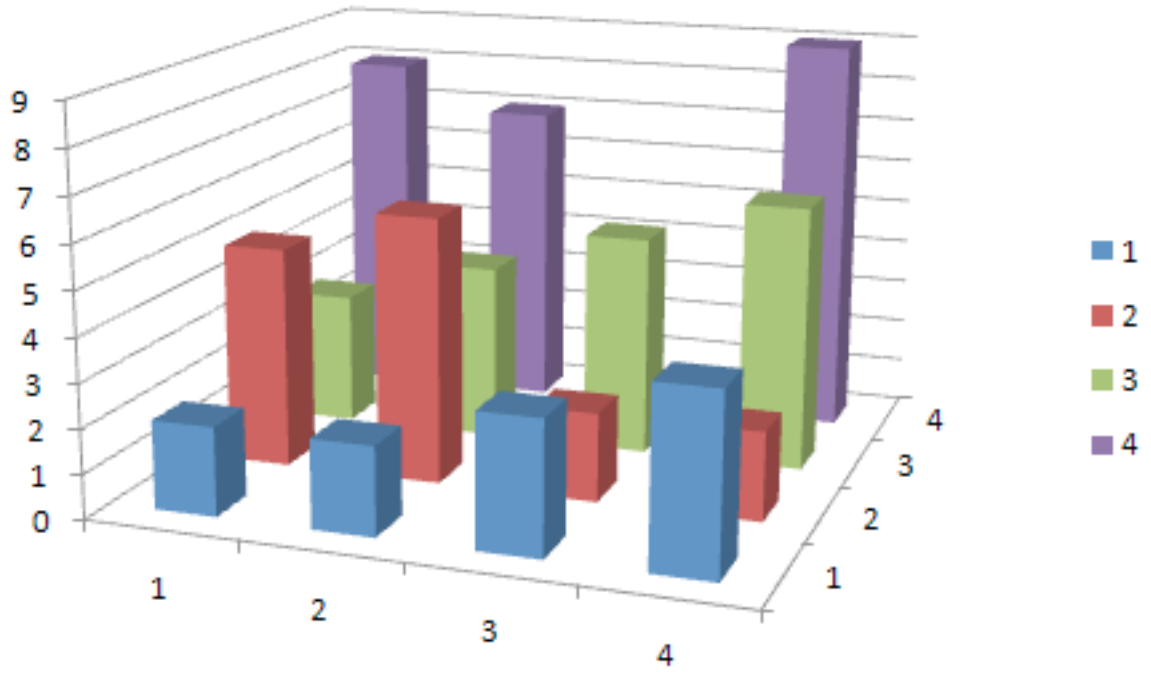

Столбиковый график (bar plot)

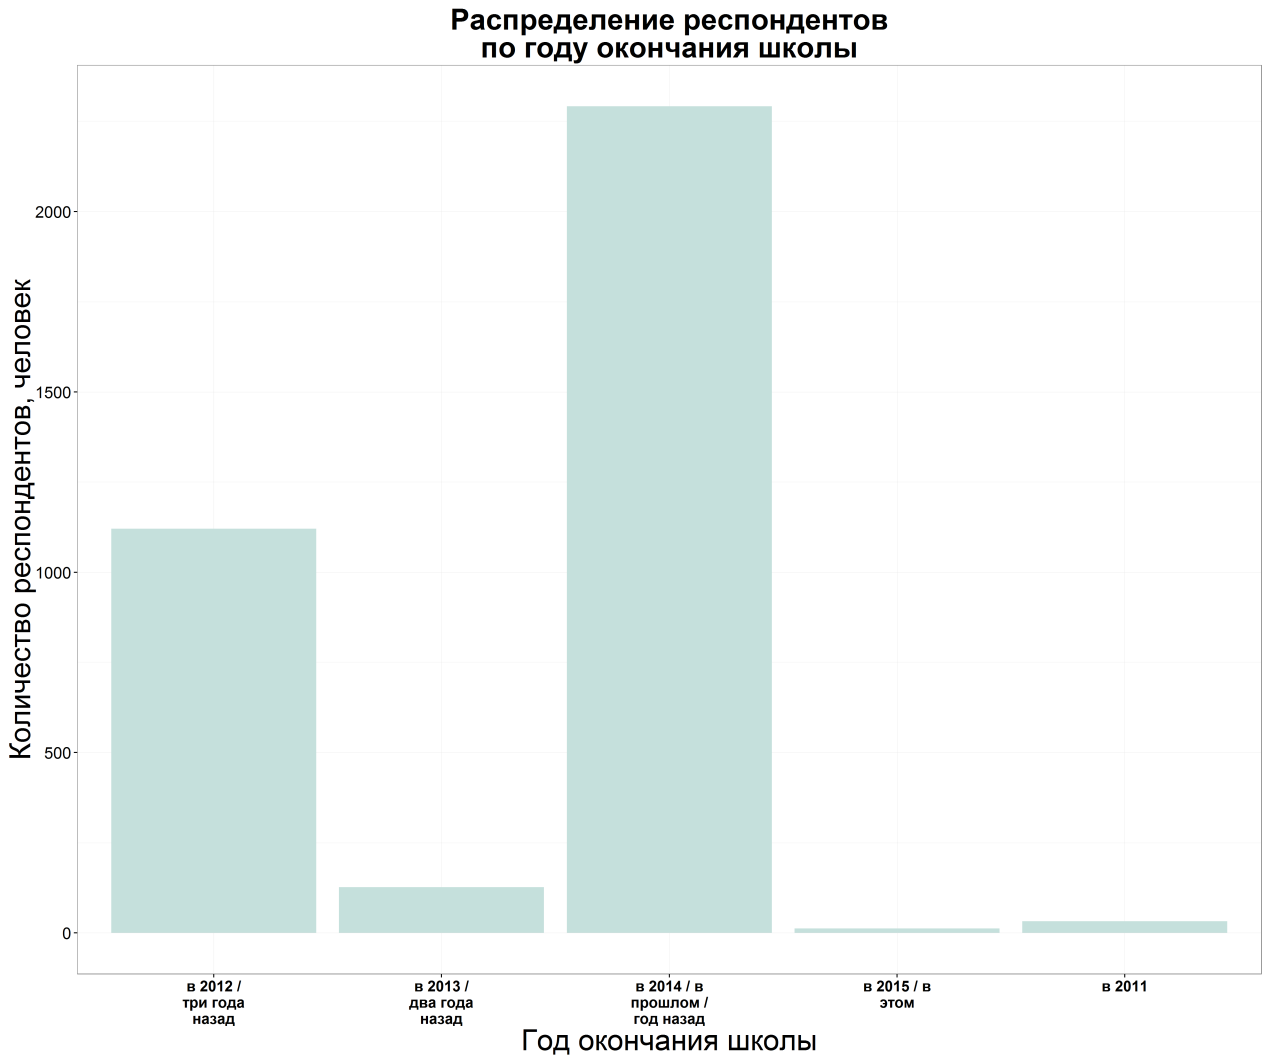

Сделаем его лучше

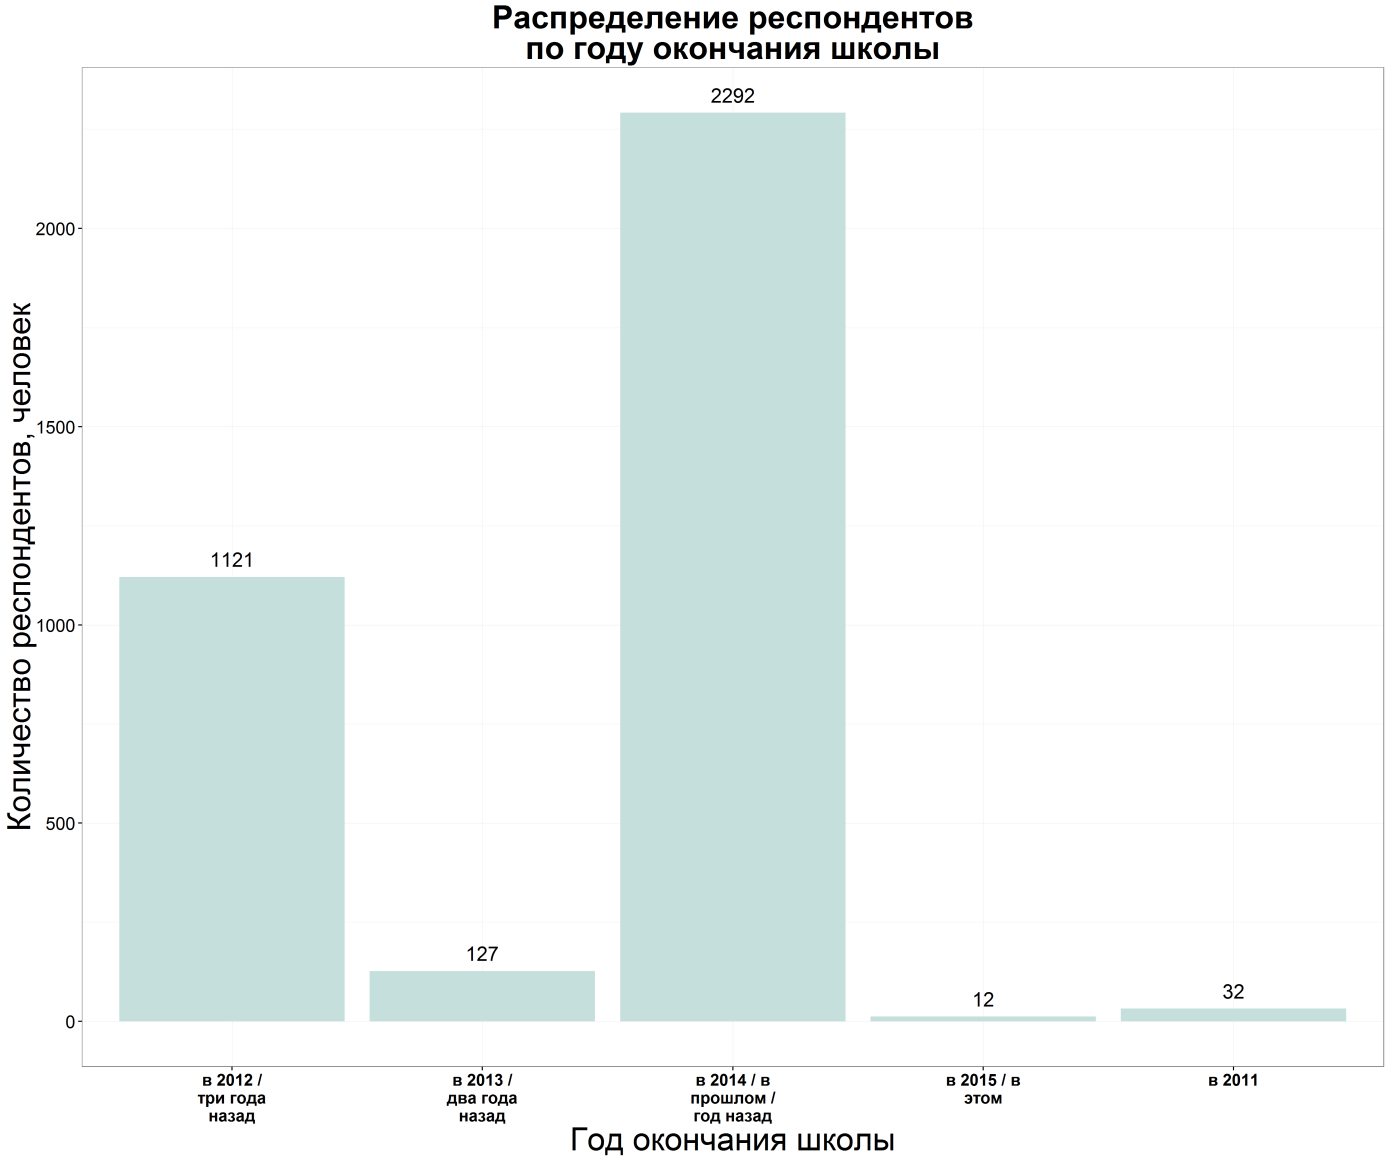

Абсолютно согласен, скорее согласен

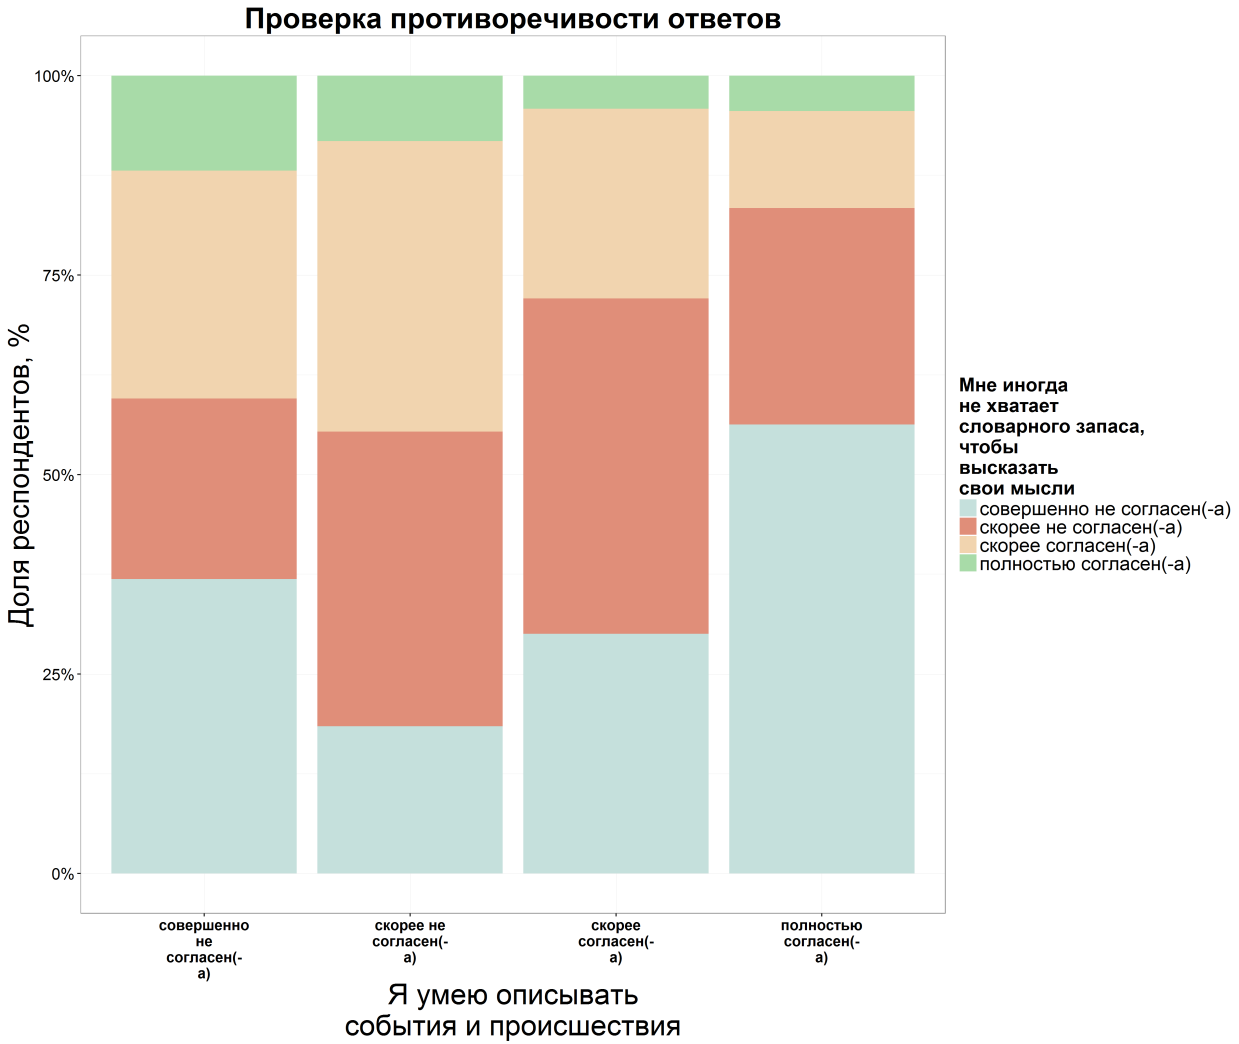

Улучшаем его

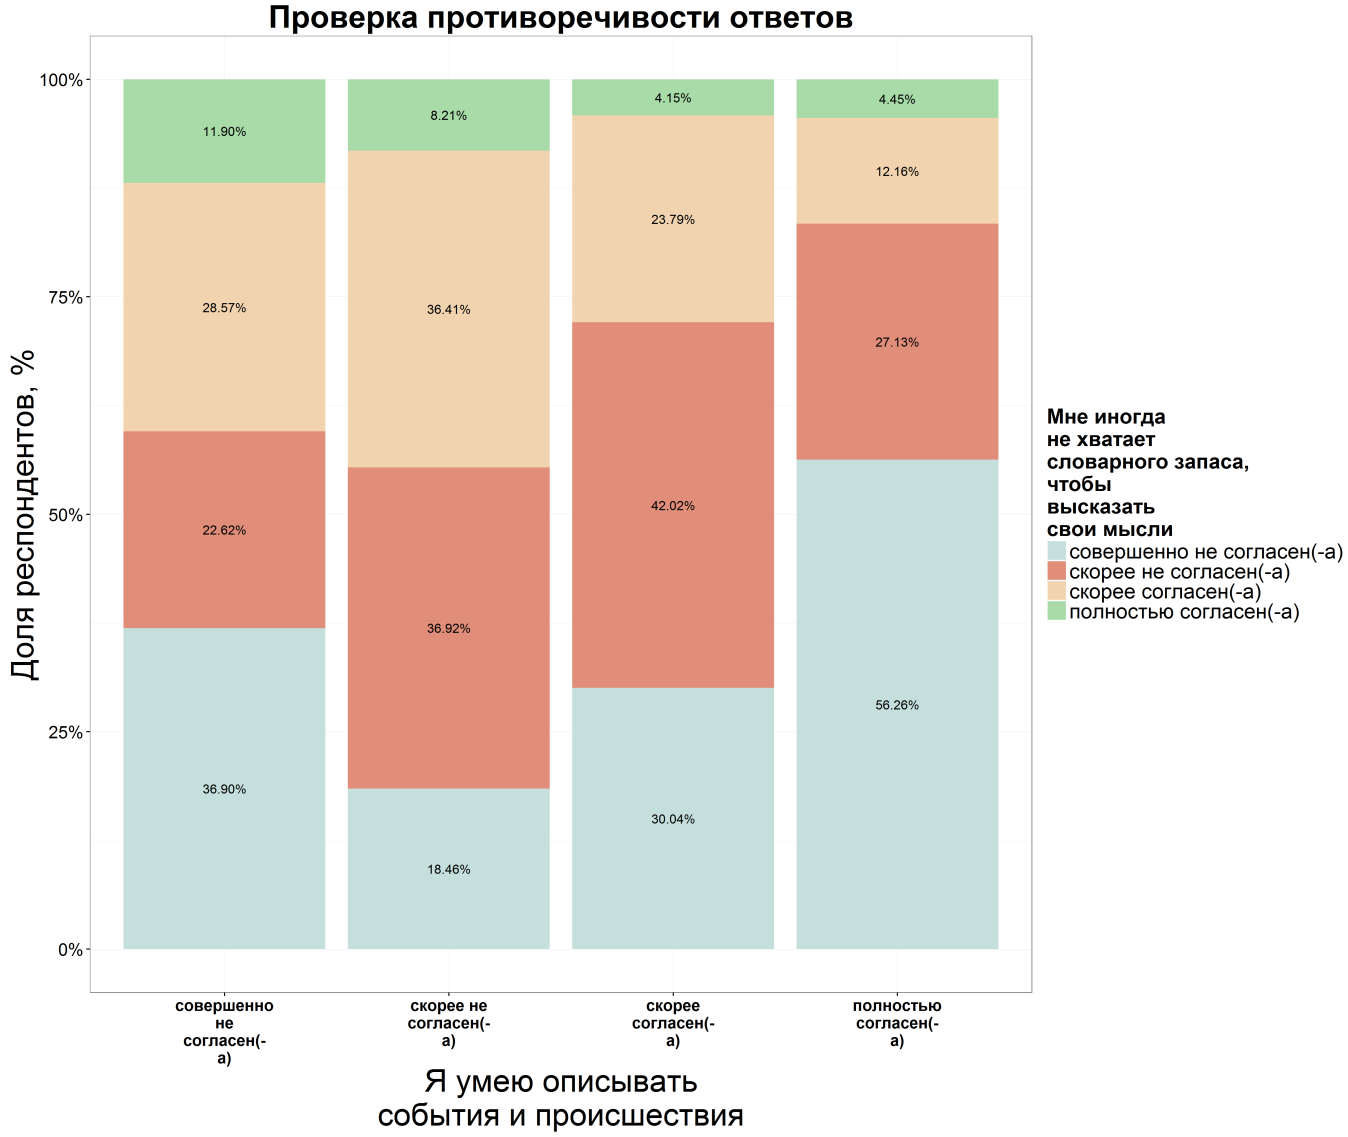

Гистограмма

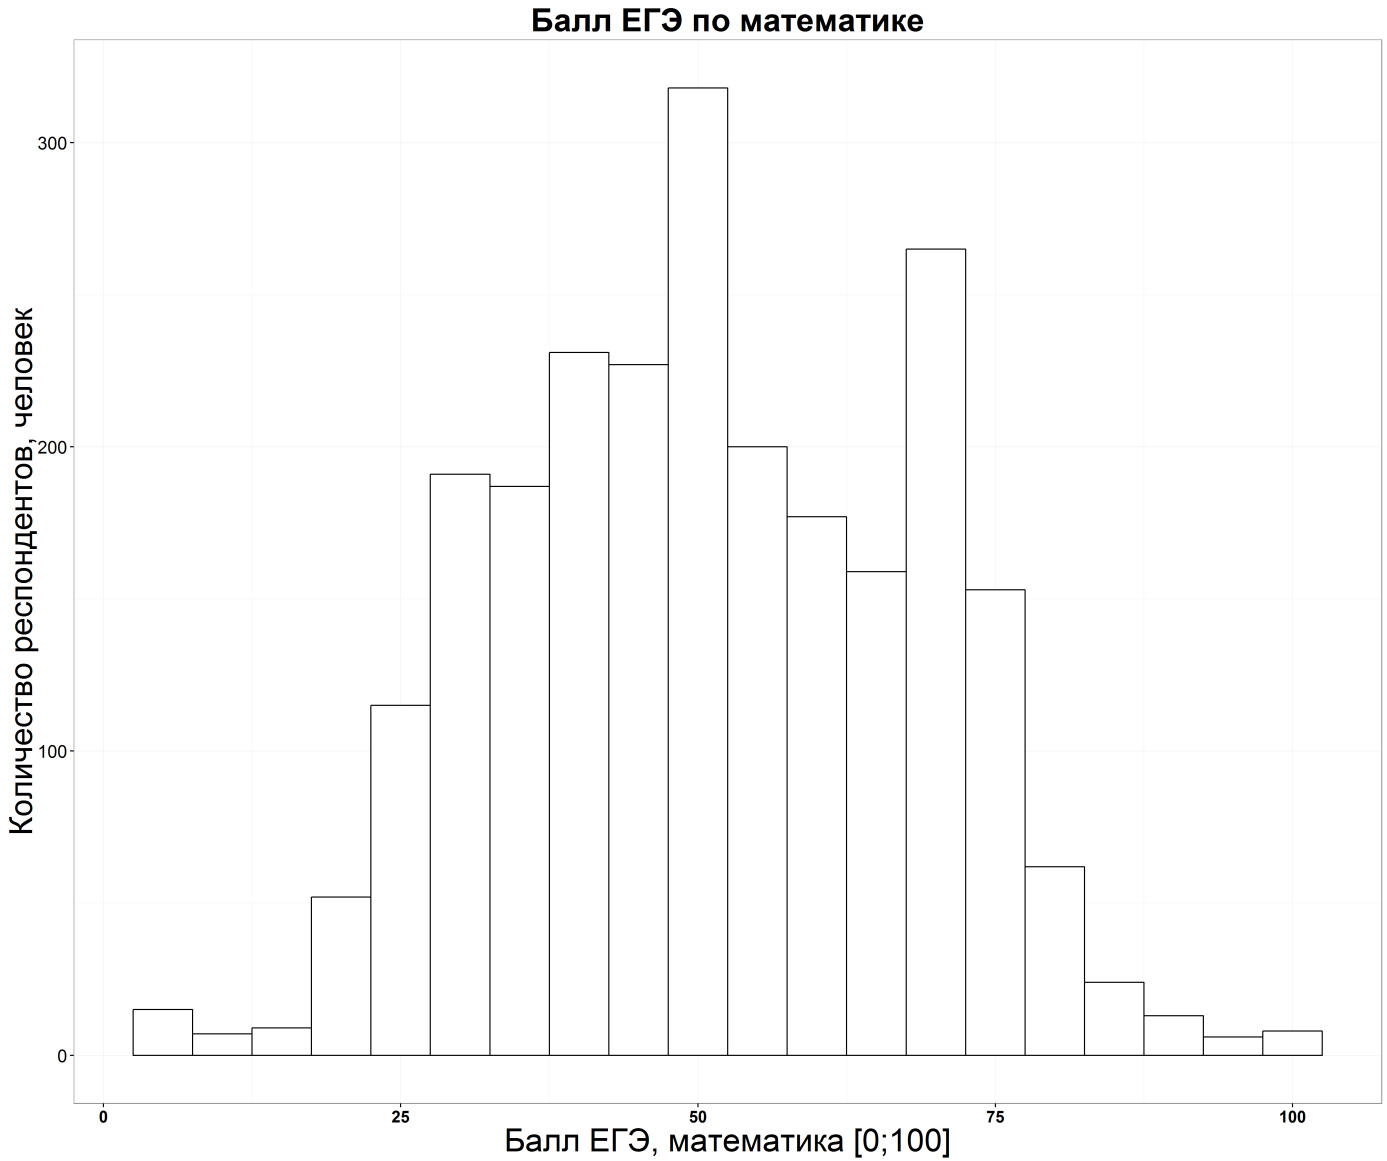

Гистограмма +1

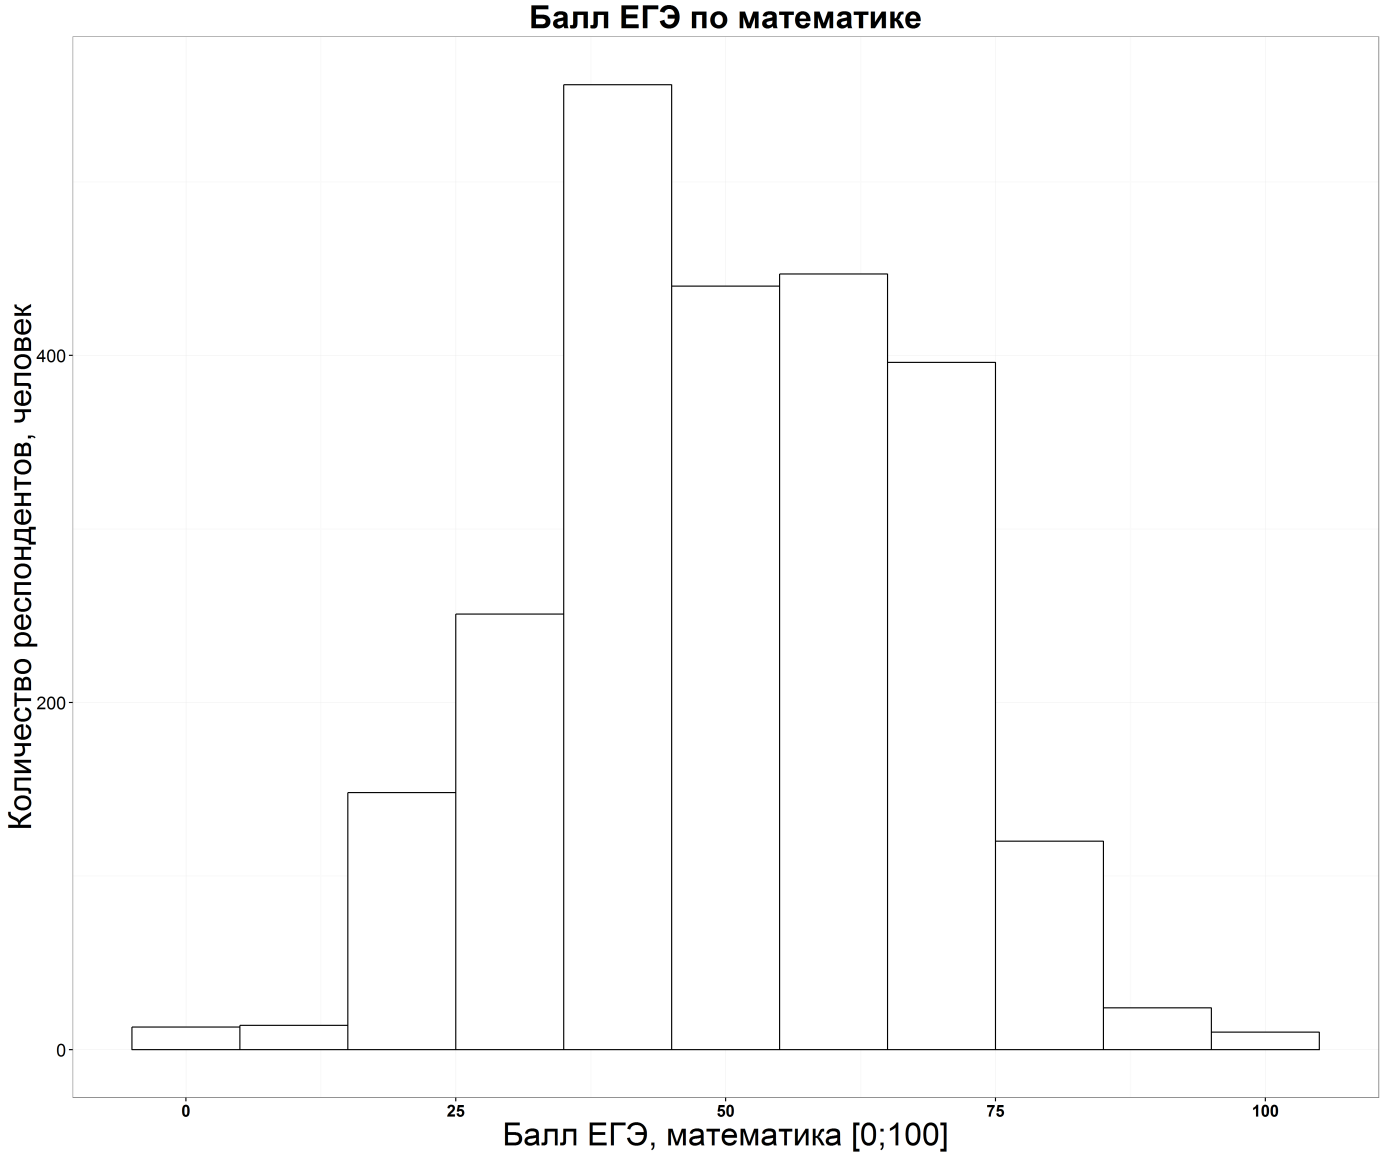

Плотность

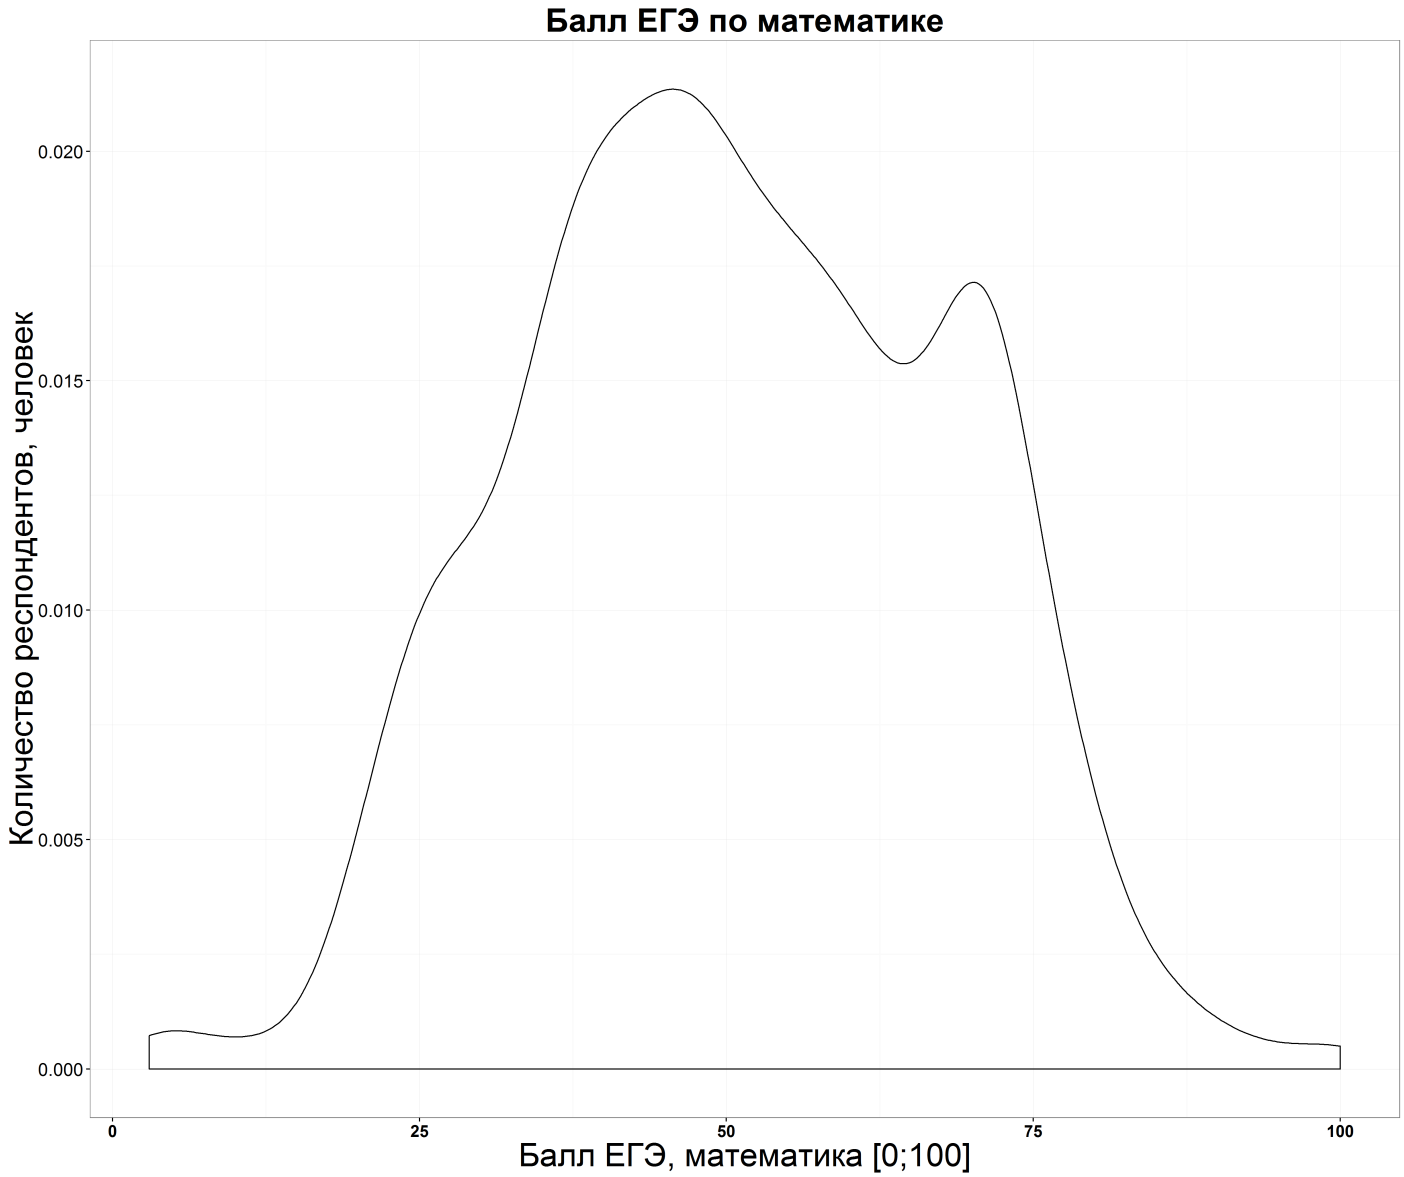
Балл ЕГЭ по математике
Количество респондентов, человек
0.020
0.015
0.010
0.005
0.000
0
25
50
75
100
Балл ЕГЭ, математика [0;100]

Что после картинок и средних?

- Модели проверяются на данных. Ваши гипотезы о взаимосвязи показателей подвергаются статистической проверке (МНК, Logit)
- Проверяется качество модели
- Выводы

Краткое содержание презентации

1. Можно предсказывать, а можно объяснять. Делаем это с помощью моделей
2. Нужно много думать про свои модели и ориентироваться на другие результаты и умные книжки по статистике
3. Прежде чем всё это делать нужно проверять данные на наличие ошибок
4. А после этого грамотно их визуализировать и описывать

Что почитать дальше?

1. Даррелл Хафф: Как лгать при помощи статистики?
2. Andrew Gelman: Data Analysis Using Regression and Multilevel/Hierarchical Models
3. Онлайн-курс по эконометрике от Бориса Демешева: https://openedu.ru/course/hse/METRIX/
4. Про картинки: https://infoactive.co/data-design/titlepage01.html
5. Рассылка «Главред» Максима Ильяхова